Atividade de Avaliação - Modelagem Preditiva

Previsão de Retorno para Revisão - Concessionária Honda

FGV - Modelagem Preditiva

Grupo: - João Victor Fortunato Teixeira Mundim (813190/2026) - Martinho Aloisio Lenz (812869/2026) - Nicolas Henrique Richardt da Silva (813138/2026) - Renato Vargas Monteiro (812872/2026) - Rodrigo Pimentel Carneiro (812440/2026)

1. Enunciado do Problema

Contexto: Previsão de retorno de clientes para revisão programada em concessionária Honda.

Pergunta de negócio: *Quais clientes têm maior probabilidade de NÃO retornar para revisão?*

Família de Modelagem: Classificação binária (Classe 0 = Não retornou, Classe 1 = Retornou)

Característica	Valor
Registros	10.467 vendas
Período	Janeiro a Dezembro de 2025
Distribuição	73,9% Não Retornou / 26,1% Retornou

Limitação: Não há data de corte ou janela de acompanhamento documentada.

2. Engenharia de Variáveis

Por que cada técnica foi utilizada:

Técnica	Justificativa
Label Encoding	Árvores e ensembles aceitam valores numéricos. Converte categorias (ex: "BROS 160") em números inteiros para processamento.
One-Hot Encoding	Regressão Logística assume linearidade. Cria variáveis binárias para evitar ordenação artificial entre categorias.
StandardScaler	Logística converge melhor com variáveis na mesma escala. Padroniza média=0 e desvio=1.
Agrupamento de cores	46 cores geram fragmentação. Agrupadas em 7 categorias principais para melhor generalização.
PERC_DESCONTO	Percentual relativo é mais comparável entre faixas de preço que valor absoluto.
Preenchimento com 0	TEM_KIT=0 indica ausência confirmada do acessório (não é dado faltante).

Variáveis: 5 categóricas + 10 numéricas. Identificadores (CHASSI) removidos dos preditores.

3. Modelagens Executadas

Modelo	Tipo	Critério
Árvore de Decisão	Base	CART com Entropia e Gini
Regressão Logística	Base	L2 (Ridge)
Random Forest	Ensemble	Entropia
Gradient Boosting	Ensemble	Deviance

Partição: 80% treino (8.373) / 20% teste (2.094). **CV:** 5-fold no treino.

4. Tentativas de Otimização (Resultados Reais)

4.1 Árvore de Decisão - Entropia vs Gini

Critério	max_depth	Acurácia CV	AUC Teste	Decisão
entropy	3	74,44%	0,7310	Profundidade insuficiente
entropy	5	74,55%	0,7546	Bom equilíbrio
entropy	**7**	**75,00%**	**0,7720**	**Melhor AUC**
gini	5	74,82%	0,7490	Inferior ao entropy

Conclusão: Entropia com depth=7 obteve melhor AUC (0,7720).

4.2 Regressão Logística - Regularização C

C	Acurácia CV	AUC Teste	Decisão
0.1	75,55%	0,8060	Regularização forte
1.0	**75,68%**	**0,8072**	**Melhor AUC**
10.0	75,68%	0,8067	Sem ganho

Conclusão: C=1.0 escolhido (melhor AUC, regularização padrão).

4.3 Random Forest - Estimadores e Profundidade

n_est	max_depth	Acurácia CV	AUC Teste	Decisão
50	5	74,64%	0,7774	Raso demais
50	10	75,15%	0,8052	Bom
100	**10**	**75,41%**	**0,8075**	**Melhor**

4.4 Gradient Boosting - Learning Rate e Profundidade

lr	max_depth	Acurácia CV	AUC Teste	Decisão
0.05	3	75,65%	0,8005	Conservador
0.05	**5**	**75,42%**	**0,8134**	**Melhor AUC**
0.1	3	75,58%	0,8066	Configuração padrão

---

5. Resultados

5.1 Quadro Comparativo Final

Baseline (sempre classe 0): 73,93%

Modelo	Acurácia	AUC-ROC	F1	Ganho vs Base
Regressão Logística	**76,84%**	0,8072	47,23%	+2,91 p.p.
Random Forest	76,79%	0,8075	40,34%	+2,86 p.p.
Gradient Boosting	76,27%	0,8066	43,33%	+2,34 p.p.
Árvore (entropy, d=7)	75,00%	0,7720	44,07%	+1,07 p.p.

5.2 Exemplos de Predição Individual

#	Modelo Moto	Financ.	Prob. Retorno	Classe Prevista	Real	Acerto
1	XRE 300 SAHARA	Não	7,6%	0 (não retorna)	0	✓
2	XRL 300 TORNADO	Não	6,9%	0 (não retorna)	1	✗
3	BROS 160 ABS	Sim	31,7%	0 (não retorna)	1	✗
4	CB 500 HORNET	Sim	36,0%	0 (não retorna)	0	✓
5	BROS 160 CBS	Não	16,4%	0 (não retorna)	1	✗

Interpretação: Os casos 2, 3 e 5 são falsos negativos - clientes que retornaram mas o modelo previu que não retornariam. O caso 3 (financiado, prob. 31,7%) mostra que mesmo com probabilidade moderada, o limiar padrão de 50% classifica como não retorno.

---

6. Resumo Final e Roteiro para Produção

6.1 Modelo Recomendado

Regressão Logística (C=1.0) - escolhida por: - Interpretabilidade dos coeficientes - Simplicidade computacional - AUC competitiva (0,8072)

A diferença entre os três melhores modelos é mínima (<0,001 AUC). GB com lr=0.05 e depth=5 obteve a maior AUC (0,8134), mas logística foi preferida pela interpretabilidade.

6.2 Roteiro de Execução

1. **Entrada:** Dados da venda no faturamento
2. **Pré-processamento:** One-Hot Encoding + StandardScaler
3. **Predição:** Probabilidade de retorno (0-100%)
4. **Risco:** 100% - probabilidade

6.3 Faixas de Ação (Proposta para Piloto)

Prob. Retorno	Risco	Ação
< 25%	ALTO	Contato imediato
25-40%	MÉDIO	Lembrete reforçado
> 40%	BAIXO	Lembrete padrão

Nota: Essas faixas são propostas para validação em piloto controlado. Os resultados históricos não garantem o efeito de uma campanha.

6.4 Desempenho Esperado

- Acurácia ~77% (vs 74% do baseline)
- Dos clientes previstos como "vai retornar", ~58% efetivamente retornam

6.5 Limitações

- Dados de um período específico (2025)

- Janela de observação não documentada
- Recomenda-se retreinamento periódico

Documento elaborado com auxílio de IA. Decisões de modelagem conduzidas pelo grupo.