Atividade de Avaliação - Modelagem Preditiva

Previsão de Retorno para Revisão - Concessionária Honda

FGV - Modelagem Preditiva

Grupo: - João Victor Fortunato Teixeira Mundim (813190/2026) - Martinho Aloisio Lenz (812869/2026) - Nicolas Henrique Richardt da Silva (813138/2026) - Renato Vargas Monteiro (812872/2026) - Rodrigo Pimentel Carneiro (812440/2026)

---

1. Enunciado do Problema

Contexto de Negócio

O problema abordado é a **previsão de retorno de clientes para revisão programada** em uma concessionária Honda. A revisão é um momento crucial no pós-venda, pois:

- Gera receita de serviços e peças
- Fortalece o relacionamento com o cliente
- Aumenta a chance de futuras vendas (troca de moto)
- Identifica problemas antes de reclamações

Problema/Oportunidade

Pergunta de negócio: *Quais clientes têm maior probabilidade de NÃO retornar para revisão?*

A identificação antecipada de clientes em risco permite ações proativas de contato, ofertas de desconto e agendamento prévio.

Família de Modelagem

Classificação binária - onde: - **Classe 0:** Cliente NÃO retornou para revisão - **Classe 1:** Cliente RETORNOU para revisão

Dataset Utilizado

Característica	Valor
Fonte	Dados reais da concessionária (anonimizados)
Registros	10.467 vendas de motocicletas
Período	Janeiro a Dezembro de 2025
Variáveis	16 (15 preditoras + 1 alvo)
Distribuição	73,9% Não Retornou / 26,1% Retornou

Limitação: O dataset não contém data de extração/corte nem horizonte de acompanhamento documentado. Os resultados assumem que o rótulo RETORNOU_REVISAO representa adequadamente o comportamento de retorno.

---

2. Engenharia de Variáveis (Feature Engineering)

2.1 Seleção de Variáveis

Variáveis utilizadas no modelo:

Variável	Tipo	Descrição
MOTO_MODELO	Categórica	Modelo da motocicleta (113 categorias)
MOTO_FAMILIA	Categórica	Família (12 categorias)
COR	Categórica	Cor simplificada (7 categorias)
ANO_MODELO	Numérica	Ano do modelo
PRECO_TABELA	Numérica	Preço de tabela
VALOR_VENDIDO	Numérica	Valor efetivamente vendido
DESCONTO_INCONDICIONAL	Numérica	Valor do desconto concedido

Variável	Tipo	Descrição
PERC_DESCONTO	Numérica	Percentual de desconto (variável derivada)
TEM_FINANCIAMENTO	Binária	Se foi financiada (0/1)
FINANCEIRA_RESUMIDA	Categórica	Banco financiador
MESES	Numérica	Prazo do financiamento
PARCELA	Numérica	Valor da parcela
TEM_KIT	Binária	Se comprou kit de acessórios
TEM_VOUCHER	Binária	Se usou voucher promocional
ONDE_MOTO_VENDIDA	Categórica	Cidade/loja da venda

Total: 5 variáveis categóricas e 10 variáveis numéricas.

Variáveis removidas: CHASSI_COMPLETO (identificador), números de notas fiscais e códigos internos.

2.2 Tratamento de Dados

Técnica	Aplicação
Valores ausentes	Preenchidos com 0 para flags e "SEM_FINANCIAMENTO" para financeira
Simplificação de cores	Agrupamento de 46 cores em 7 categorias principais
Variável derivada	PERC_DESCONTO = desconto / preço_tabela × 100
Label Encoding	Para modelos de árvore (ajustado apenas no treino)
One-Hot Encoding	Para Regressão Logística (+ StandardScaler ajustado no treino)

Nota: O pré-processamento (encoding e scaling) foi aplicado separadamente em treino e teste para evitar vazamento de dados.

---

3. Modelagens Executadas

Foram implementados os **4 modelos obrigatórios** para classificação:

#	Modelo	Tipo	Critério
1	Árvore de Decisão	Base	CART com Entropia
2	Regressão Logística	Base	L2 (Ridge)
3	Random Forest	Ensemble (Bagging)	Entropia
4	Gradient Boosting	Ensemble (Boosting)	Deviance

Particionamento: 80% treino (8.373 registros) / 20% teste (2.094 registros)
Validação: Stratified split + 5-fold Cross-Validation (apenas no treino, com shuffle)

---

4. Configuração dos Modelos

4.1 Árvore de Decisão (CART/Entropia)

Parâmetro	Valor	Justificativa
criterion	entropy	Ganho de informação
max_depth	5	Evita overfitting
min_samples_split	20	Poda mais agressiva
min_samples_leaf	10	Generalização

4.2 Regressão Logística

Parâmetro	Valor	Justificativa
penalty	l2	Regularização Ridge
C	1.0	Regularização padrão
solver	lbfgs	Eficiente para L2

4.3 Random Forest

Parâmetro	Valor	Justificativa
n_estimators	100	Trade-off performance/custo
max_depth	10	Evita overfitting
max_features	sqrt	Recomendado para classificação

4.4 Gradient Boosting

Parâmetro	Valor	Justificativa
n_estimators	100	Equilíbrio
learning_rate	0.1	Taxa padrão
max_depth	3	Árvores rasas para boosting
subsample	0.8	Stochastic GB

4.5 Tentativas de Otimização

Para cada modelo, foram considerados diferentes valores de parâmetros. A tabela abaixo resume as alternativas avaliadas:

Modelo	Parâmetro	Valores Considerados	Critério de Escolha
Árvore	max_depth	3, 5, 7, 10	5 escolhido para evitar overfitting
Árvore	min_samples_split	5, 10, 20	20 para poda mais agressiva
Logística	C	0.1, 1.0, 10	1.0 como regularização padrão
Logística	penalty	l1, l2	l2 por estabilidade numérica
RF	n_estimators	50, 100, 200	100 como trade-off custo/benefício
RF	max_depth	5, 10, None	10 para controlar overfitting
GB	learning_rate	0.05, 0.1, 0.2	0.1 como taxa padrão
GB	max_depth	3, 5, 7	3 para árvores rasas (boosting)

Observação: A seleção foi feita com base em práticas recomendadas da literatura e validação no conjunto de treino. Uma busca exaustiva (GridSearchCV) não foi realizada devido ao escopo do trabalho.

---

5. Resultados

5.1 Quadro Comparativo de Desempenho

Baseline (sempre prever classe 0): 73,93%

Modelo	Acurácia	AUC-ROC	Precisão(1)	Recall(1)	Recall(0)	F1(1)	CV Treino
Regressão Logística	**76,84%**	**0,8072**	58,18%	**39,74%**	89,92%	**47,23%**	75,68% ±0,61%
Random Forest	76,79%	0,8071	**61,19%**	30,04%	**93,28%**	40,29%	75,41% ±0,36%
Gradient Boosting	76,27%	0,8062	57,40%	34,80%	90,89%	43,33%	75,58% ±0,56%
Árvore de Decisão	74,98%	0,7546	53,96%	27,47%	91,73%	36,41%	74,55% ±0,94%

Nota sobre métricas: - **Recall(1):** Proporção de clientes que RETORNARAM e foram corretamente identificados - **Recall(0):** Proporção de clientes que NÃO RETORNARAM e foram corretamente identificados - Para identificar clientes em risco de NÃO retornar, usar probabilidade = 1 - P(retorno)

5.2 Features Mais Importantes (Random Forest)

Ranking	Variável	Importância
1°	DESCONTO_INCONDICIONAL	0,1156
2°	VALOR_VENDIDO	0,1005
3°	PRECO_TABELA	0,0933
4°	PERC_DESCONTO	0,0915
5°	PARCELA	0,0791

5.3 Insights de Negócio

- **Clientes COM financiamento** têm taxa de retorno significativamente maior (40,85% vs 15,39% - diferença de 25 p.p.)
- **Clientes com kit de acessórios** retornam mais (45,31% vs 17,22%)
- **Por loja:** Recanto das Emas (39,75%) e Valparaíso (37,58%) têm as maiores taxas; Sobradinho (15,27%) tem a menor taxa

Nota: Estas são associações observadas nos dados. Não demonstram relação causal.

---

6. Resumo Final e Roteiro para Produção

6.1 Modelo Recomendado

Regressão Logística - escolhida por sua interpretabilidade, simplicidade e bom equilíbrio entre precisão e recall.

Os três melhores modelos (Logística, RF, GB) superam o baseline em ~2,3 a 2,9 p.p. de acurácia; a Árvore ganha ~1 p.p. A diferença de AUC entre os três melhores é mínima (< 0,001), não demonstrando superioridade robusta. A Regressão Logística foi preferida por permitir interpretação direta dos coeficientes e menor custo computacional.

6.2 Roteiro de Execução em Produção

1. **Entrada:** Dados da venda no momento do faturamento
2. **Pré-processamento:** One-Hot Encoding + StandardScaler (usando transformadores do treino)
3. **Predição:** Modelo retorna probabilidade de retorno (0 a 100%)
4. **Risco de não retorno:** 100% - probabilidade de retorno

Probabilidade de Retorno	Risco	Ação Recomendada
< 25%	**ALTO**	Contato imediato, oferta de desconto na revisão
25% - 40%	**MÉDIO**	Lembrete reforçado (WhatsApp + ligação)
> 40%	**BAIXO**	Lembrete padrão por SMS

6.3 Limitações

- Modelo baseado em dados de um período específico (2025)
- Não há documentação da janela de observação do alvo
- Não considera fatores externos (sazonalidade, campanhas)
- Recomenda-se validação com piloto controlado antes de escalar

---

Documento elaborado com auxílio de ferramentas de IA para geração de código e análise. As decisões de modelagem e interpretações foram conduzidas pelo grupo.