Atividade de Avaliação - Modelagem Preditiva

Previsão de Retorno para Revisão - Concessionária Honda

FGV - Modelagem Preditiva

Grupo: - João Victor Fortunato Teixeira Mundim (813190/2026) - Martinho Aloisio Lenz (812869/2026) - Nicolas Henrique Richardt da Silva (813138/2026) - Renato Vargas Monteiro (812872/2026) - Rodrigo Pimentel Carneiro (812440/2026)

---

1. Enunciado do Problema

Contexto de Negócio

O problema abordado é a **previsão de retorno de clientes para a primeira revisão programada** em uma concessionária Honda. A revisão é um momento crucial no pós-venda, pois:

- Gera receita de serviços e peças
- Fortalece o relacionamento com o cliente
- Aumenta a chance de futuras vendas (troca de moto)
- Identifica problemas antes de reclamações

Problema/Oportunidade

Pergunta de negócio: *Quais clientes têm maior probabilidade de NÃO retornar para a primeira revisão?*

A identificação antecipada de clientes em risco permite: - Ações proativas de contato (ligação, WhatsApp) - Ofertas de desconto ou facilidades - Agendamento prévio no momento da venda - Aumento da taxa de retenção no pós-venda

Família de Modelagem

Classificação binária - onde: - **Classe 0:** Cliente NÃO retornou para revisão - **Classe 1:** Cliente RETORNOU para revisão

Dataset Utilizado

Característica	Valor
Fonte	Dados reais da concessionária (anonimizados)
Registros	10.467 vendas de motocicletas
Período	Janeiro a Outubro de 2025
Variáveis	16 (15 preditoras + 1 alvo)
Distribuição	73,9% Não Retornou / 26,1% Retornou

---

2. Engenharia de Variáveis (Feature Engineering)

2.1 Seleção de Variáveis

Variáveis utilizadas no modelo:

Variável	Tipo	Descrição
MOTO_MODELO	Categórica	Modelo da motocicleta (CG 160, Bros, Biz, etc.)
MOTO_FAMILIA	Categórica	Família (Utility, Entry, Leisure, Scooter, etc.)
COR	Categórica	Cor simplificada (6 categorias)
ANO_MODELO	Numérica	Ano do modelo
PRECO_TABELA	Numérica	Preço de tabela
VALOR_VENDIDO	Numérica	Valor efetivamente vendido
DESCONTO_INCONDICIONAL	Numérica	Valor do desconto concedido
PERC_DESCONTO	Numérica	Percentual de desconto (variável derivada)
TEM_FINANCIAMENTO	Binária	Se foi financiada (0/1)
FINANCEIRA_RESUMIDA	Categórica	Banco financiador
MESES	Numérica	Prazo do financiamento
PARCELA	Numérica	Valor da parcela
TEM_KIT	Binária	Se comprou kit de acessórios
TEM_VOUCHER	Binária	Se usou voucher promocional
ONDE_MOTO_VENDIDA	Categórica	Cidade/loja da venda

Variáveis removidas (dados sensíveis ou sem valor preditivo): - CHASSI_COMPLETO (identificador) - Números de notas fiscais e códigos internos - Dados de revisões futuras (evitar data leakage)

2.2 Tratamento de Dados

Técnica	Aplicação
Valores ausentes	Preenchidos com 0 para flags (TEM_*) e "SEM_FINANCIAMENTO" para financeira
Simplificação de cores	Agrupamento de 46 cores em 7 categorias principais
Variável derivada	PERC_DESCONTO = desconto / preço_tabela × 100
Label Encoding	Para modelos de árvore (6 variáveis categóricas)
One-Hot Encoding	Para Regressão Logística (+ StandardScaler)

---

3. Modelagens Executadas

Foram implementados os **4 modelos obrigatórios** para classificação:

#	Modelo	Tipo	Critério
1	Árvore de Decisão	Base	Entropia (ID3)
2	Regressão Logística	Base	L2 (Ridge)
3	Random Forest	Ensemble (Bagging)	Entropia
4	Gradient Boosting	Ensemble (Boosting)	Deviance

Particionamento: 80% treino (8.373 registros) / 20% teste (2.094 registros)
Validação: Stratified split + 5-fold Cross-Validation

4. Tentativas de Otimização

4.1 Árvore de Decisão

Parâmetro	Valores Testados	Escolhido	Justificativa
criterion	gini, entropy	**entropy**	Melhor AUC-ROC
max_depth	3, 5, 7, 10	**5**	Evita overfitting
min_samples_split	5, 10, 20	**20**	Poda mais agressiva
min_samples_leaf	5, 10, 20	**10**	Generalização

4.2 Regressão Logística

Parâmetro	Valores Testados	Escolhido	Justificativa
penalty	l1, l2	**l2**	Mais estável
C	0.1, 1.0, 10	**1.0**	Regularização padrão

4.3 Random Forest

Parâmetro	Valores Testados	Escolhido	Justificativa
n_estimators	50, 100, 200	**100**	Trade-off performance/custo
max_depth	5, 10, None	**10**	Evita overfitting
max_features	sqrt, log2	**sqrt**	Recomendado para classificação

4.4 Gradient Boosting

Parâmetro	Valores Testados	Escolhido	Justificativa
n_estimators	50, 100, 150	**100**	Equilíbrio
learning_rate	0.05, 0.1, 0.2	**0.1**	Taxa padrão
max_depth	3, 5, 7	**3**	Árvores rasas para boosting
subsample	0.8, 1.0	**0.8**	Stochastic GB

5. Resultados

5.1 Quadro Comparativo de Desempenho

Modelo	Acurácia	AUC-ROC	Precisão	Recall	F1-Score	CV (5-fold)
Random Forest	**76,84%**	**0,8075**	**61,42%**	30,04%	40,34%	58,35% ±14,74%

Modelo	Acurácia	AUC-ROC	Precisão	Recall	F1-Score	CV (5-fold)
Regressão Logística	76,74%	0,8071	57,87%	**39,74%**	**47,12%**	57,39% ±14,22%
Gradient Boosting	76,31%	0,8066	57,58%	34,80%	43,38%	59,43% ±14,08%
Árvore de Decisão	74,98%	0,7546	53,96%	27,47%	36,41%	60,41% ±12,16%

5.2 Features Mais Importantes (Random Forest)

Ranking	Variável	Importância	Interpretação
1°	DESCONTO_INCONDICIONAL	0,1166	Desconto oferecido é forte preditor
2°	VALOR_VENDIDO	0,1005	Valor da moto influencia retorno
3°	PRECO_TABELA	0,0933	Faixa de preço correlaciona com perfil
4°	PERC_DESCONTO	0,0915	Percentual de desconto impacta decisão
5°	PARCELA	0,0791	Clientes financiados têm outro perfil
6°	MOTO_MODELO	0,0744	Alguns modelos retornam mais
7°	ONDE_MOTO_VENDIDA	0,0733	Diferença por loja/região
8°	TEM_KIT	0,0717	Clientes com acessórios mais engajados

5.3 Insights de Negócio

- **Clientes COM financiamento** têm taxa de retorno ligeiramente maior
- **Motos da família Utility** têm menor retorno que Leisure
- **Lojas do Gama e Valparaíso** têm melhores taxas de retorno
- **Compradores de kit de acessórios** tendem a retornar mais

---

6. Resumo Final e Roteiro para Produção

6.1 Modelo Recomendado

Random Forest - maior capacidade discriminativa (AUC-ROC = 0,8075) e melhor precisão (61,42%)

Alternativa: **Regressão Logística** - se priorizar Recall (39,74%) para identificar mais clientes em risco

6.2 Roteiro de Execução em Produção

1. **Entrada:** Dados da venda no momento do faturamento
2. **Pré-processamento:** Label Encoding nas categóricas
3. **Predição:** Modelo retorna probabilidade de retorno (0 a 100%)
4. **Ação baseada no resultado:**

Probabilidade de Retorno	Risco	Ação Recomendada
$< 20\%$	**ALTO**	Contato imediato, oferta de desconto na revisão
20% - 40%	**MÉDIO**	Lembrete reforçado (WhatsApp + ligação)
$> 40\%$	**BAIXO**	Lembrete padrão por SMS

6.3 Desempenho Esperado

- **Identificação geral:** ~77% de acerto (acurácia do Random Forest)
- **Dos identificados como "vai retornar":** ~61% efetivamente retornam (precisão)
- **Capacidade discriminativa:** AUC-ROC de 0,81 indica boa separação entre classes
- **Melhoria potencial:** Aumento de 5-10% na taxa de retorno com ações direcionadas

6.4 Limitações

- Modelo baseado em dados de um período específico (2025)
- Não considera fatores externos (sazonalidade, campanhas)
- Recomenda-se retreinamento semestral

Documento elaborado com auxílio de ferramentas de IA para geração de código e análise. As decisões de modelagem e interpretações foram conduzidas pelo grupo.